
Clase 120 — Funciones y grafos (autograph)

Parte: 2 — Deep Learning · Fuente: Géron, cap. 12 § TF Functions and Graphs. Duración estimada: 55 min.

Clase 120 — Funciones y grafos (autograph)

Parte: 2 — Deep Learning · Fuente: Géron, cap. 12 § TF Functions and Graphs. Duración estimada: 55 min.

Objetivo

Entender qué hace `@tf.function` —compila una función Python a un grafo TF estático, acelerando 2-10× y permitiendo deploy en TF Serving / TFLite—. Conocer AutoGraph (traduce automáticamente `if/for/while` Python a operaciones TF), saber los gotchas clásicos (efectos colaterales, prints, listas Python) y cuándo el decorator deteriora la experiencia de debugging.

Resultados de aprendizaje

Al finalizar, el estudiante podrá:

- Aplicar `@tf.function` a una función custom y verificar speedup.
- Identificar cuándo NO usarlo (debugging, lógica con efectos colaterales no determinísticos).
- Entender retracing: cada vez que cambias la shape o dtype del input, TF reconstruye el grafo.
- Usar `tf.function(input_signature=...)` para evitar retracing.
- Diferenciar eager mode (default, dinámico) de graph mode (compilado).

Temas

- Eager vs graph execution.
- `@tf.function` y AutoGraph.
- Retracing: por qué pasar Python ints vs tensors causa retraces.
- Print en grafo: `tf.print` (corre en graph) vs `print` (solo en tracing).
- Cuándo `@tf.function` vale la pena (loops, training step) y cuándo no (one-shot, debugging).

Definiciones y características

- Eager mode: cada op se ejecuta inmediatamente. Default en TF 2+. Como NumPy.
- Graph mode: las ops se ensamblan en un grafo y se ejecutan después. Más rápido, deployable.
- `@tf.function`: convierte una función Python en un ConcreteFunction (grafo).
- AutoGraph: subsistema que traduce `if/for/while` a `tf.cond/tf.while_loop`.
- Retracing: rebuild del grafo cuando cambian shape/dtype de inputs. Caro.
- `input_signature`: tupla de TensorSpec que fija las shapes esperadas → no retracing.

Dataset / recursos

- Operaciones aisladas para medir velocidad.
- Librerías: tensorflow, time.

Ejercicios

1. Speedup básico: definir `def f(x): return tf.reduce_sum(x * 2 + 3x + 1)`. Medir tiempo eager vs `@tf.function`-wrapped en un loop de 10 000 iteraciones.
2. Retracing: definir una función con `@tf.function`. Llamarla con tensores de shapes distintas; usar `tf.config.experimental_run_functions_eagerly(True)` y `print` para detectar retraces.
3. AutoGraph: una función con un `for` Python y un `if`. Verificar que se convierte correctamente (`tf.autograph.to_code(f)`).
4. `tf.print` vs `print`: dentro de `@tf.function`, demostrar que `print` solo se ejecuta en tracing (1ª llamada), `tf.print` siempre.
5. `input_signature`: fijar `input_signature` para evitar retracing con `shape (None, 784)`.

Homework verifiable

Implementar un training loop minimalista (sin Keras) con y sin `@tf.function`:

1. Modelo simple en numpy/TF (regresión lineal).
2. Loop manual de 1 000 iteraciones.
3. Mismo loop wrapped con `@tf.function`.
4. Comparar tiempo total.

Criterio de aceptación: la versión `@tf.function` debe ser $\geq 2\times$ más rápida (en CPU, más en GPU).

Errores comunes

Síntoma / mensaje	Causa y cómo arreglar
<code>print</code> no aparece dentro de <code>@tf.function</code> de	Solo corre en tracing. Fix: <code>tf.print</code> para
Función retrace en cada llamada	Pasás Python ints/strings como argumentos.
<code>list.append()</code> dentro de <code>@tf.function</code> no fu	Listas Python no se preservan en grafo. Fi
<code>if x > 0</code> : con tensor <code>x</code> → error o warning	AutoGraph debería convertirlo a <code>tf.cond</code> . F
<code>np.random</code> dentro de <code>@tf.function</code> siempre d	Se evalúa una vez en tracing. Fix: usar <code>tf</code>

Preguntas frecuentes

¿Cuándo `@tf.function`?

Para funciones que se llaman muchas veces (training step, custom layers complejas). NO para funciones one-shot, debugging, o muy simples.

¿`@tf.function` y debugging?

Hacé el debugging en eager (sin decorator). Una vez que funciona, agregás `@tf.function` para producción.

¿Cómo veo el grafo generado?

`tf.autograph.to_code(f.python_function)` te da el Python equivalente que generó AutoGraph. Útil para entender qué hizo.

¿`jit_compile=True` qué hace?

`@tf.function(jit_compile=True)` activa XLA, otra capa de optimización (fusión de ops). Mejora velocidad otro 1.5-3×, especialmente en TPU.

¿En Keras hace falta?

No para `model.fit` (ya está jitted). Sí para custom training loops (clase 108) y para custom layers/models complejos.

Referencias

- Géron, cap. 12 — TF Functions and Graphs.
- TF — Better performance with `tf.function`.
- TF — AutoGraph.

Material descargable

- Guía explicativa (PDF) — versión imprimible con todo el contenido de la clase.
- Presentación (PPTX) — deck PowerPoint listo para proyectar en clase.
- Notebook ejecutable (.ipynb) — ábrilo desde el laboratorio del programa o desde Jupyter.

Siguiente clase

Clase 121 — Custom training loops (+ PyTorch & PyTorch Lightning)

Apéndice: notebook (primer bloque)

Primera celda ejecutable del notebook de la clase.

```
import time
import tensorflow as tf
tf.random.set_seed(42)

def f_eager(x):
    return tf.reduce_sum(x * 2 + 3 * x + 1)

@tf.function
def f_grafo(x):
    return tf.reduce_sum(x * 2 + 3 * x + 1)

x = tf.random.normal((1000,))
print("eager:", float(f_eager(x)))
print("grafo:", float(f_grafo(x)))
print("tipo de f_grafo:", type(f_grafo).__name__)
```

Archivos complementarios

- notebook.ipynb