
Clase 157 — Variational Autoencoders (VAE)

Parte: 2 — Deep Learning · Fuente: Géron, cap. 17 § Variational Autoencoders + Kingma & Welling (2014). Duración estimada: 80 min.

Clase 157 — Variational Autoencoders (VAE)

Parte: 2 — Deep Learning · Fuente: Géron, cap. 17 § Variational Autoencoders + Kingma & Welling (2014). Duración estimada: 80 min.

Objetivo

Construir un VAE (Variational Autoencoder, Kingma & Welling 2014) — variante probabilística del AE que aprende una distribución sobre el latent en lugar de un punto: encoder outputs μ , σ de una gaussiana; sampling + reparametrization trick para mantener gradientes. Resultado: latent space continuo y estructurado → permite generación, interpolación entre samples.

Resultados de aprendizaje

Al finalizar, el estudiante podrá:

- Implementar encoder que devuelve $(\mu, \log \sigma^2)$; sample con $z = \mu + \sigma \cdot \epsilon$ (reparametrization).
- Loss = reconstruction_loss + $\beta \cdot \text{KL}(N(\mu, \sigma^2) \parallel N(0, I))$.
- Generar samples nuevos: muestrear $z \sim N(0, I)$, pasar por el decoder.
- Interpolan en el latent space y verificar transiciones suaves.
- Reconocer que VAE produce outputs borrosos (consecuencia del MSE/BCE) — motivó GANs (132).

Temas

- ELBO (Evidence Lower BOund): $\log p(x) \geq E[\log p(x|z)] - \text{KL}(q(z|x) \parallel p(z))$.
- Reparametrization trick: para back-propagar a través del sample.
- β -VAE: subir β fuerza latent más disentangled.
- Posterior collapse: cuando el decoder ignora z .

Definiciones y características

- $q(z|x)$: encoder, devuelve $\mu(x)$, $\sigma(x)$.
- $p(z)$: prior, típicamente $N(0, I)$.
- $p(x|z)$: decoder.
- ELBO: lower bound de log-likelihood que se maximiza.
- KL divergence: $\text{KL}(N(\mu, \sigma^2) \parallel N(0, I)) = 0.5 \cdot \sum (1 + \log \sigma^2 - \mu^2 - \sigma^2)$ con signo.
- β -VAE: scale del término KL, controla trade-off reconstrucción vs estructura latente.

Dataset / recursos

- Fashion-MNIST / MNIST / Celeb-A (cara).
- Librerías: tensorflow, keras.

Ejercicios

1. VAE básico: encoder $\rightarrow (z_mean, z_log_var) \rightarrow$ sample $\rightarrow$ decoder. Loss combinada. Entrenar en

MNIST.

2. Sampling: muestrear $z \sim N(0, I)$ de tamaño (100, latent_dim). Pasar por decoder. Visualizar las 100 imágenes generadas.
3. Interpolación: dos imágenes A y B $\rightarrow z_A, z_B$. Generar 10 imágenes en interpolación lineal entre z_A y z_B . Visualizar.
4. β -VAE: probar $\beta=1, \beta=5, \beta=10$. Comparar disentanglement vs blurriness.
5. Posterior collapse: con LR alto, el encoder colapsa a $\mu=0, \sigma=1$. Diagnosticar mirando $z_mean.std()$ cerca de 0.

Homework verifiable

VAE sobre Fashion-MNIST:

1. Encoder convolucional, latent_dim=10.
2. Decoder simétrico.
3. Loss: BCE + KL.
4. Entrenar 30 épocas; generar 64 muestras nuevas y visualizar grid.
5. Interpolación entre 2 prendas distintas.

Criterio de aceptación: muestras generadas son reconocibles como prendas (aunque borrosas); interpolación es suave.

Errores comunes

Síntoma / mensaje	Causa y cómo arreglar
Posterior collapse: encoder predice $\mu=0, \sigma$	KL domina. Fix: KL annealing (subir β grad
Outputs borrosos	Consecuencia inherente de VAE + MSE/BCE. F
KL = 0 $\rightarrow$ AE puro	$\beta=0 \rightarrow$ no es VAE. Fix: $\beta > 0$.
Sampleo con $z \sim N(\mu, \sigma)$ en lugar de $N(0, I)$	Eso es reconstrucción + ruido, no generaci
Generación muestra solo 1 modo	Posterior collapse parcial. Fix: architect

Preguntas frecuentes

¿VAE en 2026?

Como generador end-to-end: superado por difusión. Como encoder dentro de Stable Diffusion (latent space comprimido), sí.

¿Por qué reparametrization trick?

Sin él, no se puede back-propagar a través del sample (operación estocástica). Con $z = \mu + \sigma \cdot \epsilon$, ϵ es noise externo independiente, gradientes fluyen por μ y σ .

¿Qué es disentanglement?

Cada dimensión latente captura un factor independiente (rotación, color, tamaño). β -VAE y FactorVAE lo persiguen explícitamente.

¿VAE para texto?

Sí, VAE de texto histórico. Hoy LLMs autoregresivos lo cubren mejor.

¿VQ-VAE?

VAE con codebook discreto. Base de muchos modelos modernos: DALL-E 1, Jukebox, EnCodec (audio). Importante.

Referencias

- Géron, cap. 17 — Variational Autoencoders.
- Kingma & Welling (2014), Auto-Encoding Variational Bayes, ICLR.
- Higgins et al. (2017), β -VAE, ICLR.
- van den Oord et al. (2017), Neural Discrete Representation Learning (VQ-VAE), NeurIPS.

Material descargable

- Guía explicativa (PDF) — versión imprimible con todo el contenido de la clase.
- Presentación (PPTX) — deck PowerPoint listo para proyectar en clase.
- Notebook ejecutable (.ipynb) — ábrilo desde el laboratorio del programa o desde Jupyter.

Siguiente clase

Clase 158 — GANs: DCGAN, Progressive GAN, StyleGAN

Apéndice: notebook (primer bloque)

Primera celda ejecutable del notebook de la clase.

```
try:
    import tensorflow as tf
    from tensorflow import keras
    from tensorflow.keras import layers
    HAS_TF = True
    tf.random.set_seed(42)
    print('tensorflow:', tf.__version__)
except Exception as e:
    HAS_TF = False
    print('tensorflow no instalado. Motivo:', type(e).__name__)

import numpy as np
np.random.seed(42)
latent_dim = 2
```

Archivos complementarios

- notebook.ipynb