
Clase 175 — Distribuciones: normal, binomial, Poisson, exponencial

Parte: 3 — Estadística Inferencial y Causal · Fuente: ISLP, cap. 2 + Bruce & Bruce, cap. 2 Data and Sampling Distributions. Duración estimada: 70 min.

Clase 175 — Distribuciones: normal, binomial, Poisson, exponencial

Parte: 3 — Estadística Inferencial y Causal · Fuente: ISLP, cap. 2 + Bruce & Bruce, cap. 2 Data and Sampling Distributions. Duración estimada: 70 min.

Objetivo

Reconocer las cuatro distribuciones de probabilidad que aparecen en el 90 % de los problemas reales de data science —normal, binomial, Poisson, exponencial— sabiendo qué fenómeno modela cada una, cuáles son sus parámetros, cómo simularlas con `scipy.stats` / `numpy.random`, y cómo verificar empíricamente si los datos realmente siguen esa distribución antes de aplicar un test que la asuma.

Resultados de aprendizaje

Al finalizar, el estudiante podrá:

- Identificar la distribución apropiada para un fenómeno descrito en lenguaje natural (conteos raros → Poisson, éxitos/fracasos → binomial, tiempos entre eventos → exponencial, sumas/promedios → normal por TCL).
- Calcular media, varianza y cuantiles teóricos con `scipy.stats.{norm, binom, poisson, expon}` (`.mean()`, `.var()`, `.ppf()`, `.pdf()`/`.pmf()`).
- Simular muestras con `rng = np.random.default_rng(seed)` y comparar histograma vs PDF/PMF teórica.
- Aplicar un Q-Q plot (`scipy.stats.probplot`) y un Kolmogorov-Smirnov (`scipy.stats.kstest`) para validar normalidad.
- Reconocer cuándo el Teorema Central del Límite justifica usar normal aunque los datos crudos no lo sean.

Temas

#	Tema	Por qué importa
1	Distribución normal $N(\mu, \sigma^2)$	Base de t-test, ANOVA, intervalos de confi
2	Distribución binomial $\text{Bin}(n, p)$	Conversiones A/B, click-through rate, prop
3	Distribución de Poisson $\text{Poi}(\lambda)$	Eventos raros por unidad de tiempo/área (f
4	Distribución exponencial $\text{Exp}(\lambda)$	Tiempos entre eventos Poisson (churn, time
5	Teorema Central del Límite (TCL)	Por qué la normal aparece aunque los datos
6	Verificación empírica: Q-Q plot + KS test	Antes de asumir, mirá.

Definiciones y características

- PDF (Probability Density Function): para variables continuas. $f(x)$ no es probabilidad; la probabilidad es $\int f(x) dx$ sobre un intervalo. $f(x)$ puede ser > 1 .
- PMF (Probability Mass Function): para variables discretas. $P(X = k)$ directo. Siempre en $[0, 1]$.
- CDF (Cumulative Distribution Function) $F(x) = P(X \leq x)$: en `scipy` `.cdf()`. Su inversa es `.ppf()` (quantile

function), útil para construir intervalos.

- Normal $N(\mu, \sigma^2)$: simétrica, soporte en $\mathbb{R}$. Regla 68-95-99.7 ($1\sigma, 2\sigma, 3\sigma$). Es la única distribución cuya suma de variables independientes sigue siendo de la misma familia exacta.
- Binomial $\text{Bin}(n, p)$: suma de n ensayos Bernoulli independientes con éxito p . $E[X]=np$, $\text{Var}[X]=np(1-p)$. Para n grande y p no extrema, $\approx N(np, np(1-p))$ — esto es lo que justifica los z-tests de proporciones.
- Poisson $\text{Poi}(\lambda)$: conteo de eventos raros independientes en un intervalo fijo. $E[X]=\text{Var}[X]=\lambda$ (¡equidispersión!). Si tus datos tienen $\text{Var}/\text{Mean} \gg 1$, hay sobre-dispersión y Poisson no aplica — considerar binomial negativa.
- Exponencial $\text{Exp}(\lambda)$: tiempo entre eventos Poisson. Memoryless: $P(X > s+t \mid X > s) = P(X > t)$. Por eso modela mal cosas con desgaste (un motor de 10 años no falla igual que uno nuevo).
- TCL: si $X_1, \dots, X_n$ son i.i.d. con media μ y varianza finita σ^2 , entonces $(\bar{X} - \mu) / (\sigma/\sqrt{n}) \rightarrow N(0, 1)$ cuando $n \rightarrow \infty$. Regla práctica: $n \geq 30$ alcanza, salvo distribuciones muy asimétricas.
- Q-Q plot: scatter de cuantiles muestrales vs cuantiles teóricos. Si los puntos caen sobre la diagonal, los datos siguen la distribución.

Dataset / recursos

- Conteo de llamados a un call center por hora (sintético): `rng.poisson(lam=4.2, size=10_000)` → Poisson.
- Datos reales: `seaborn.load_dataset('tips')` para chequear normalidad de `total_bill` (no es normal, asimétrico positivo — buen contraejemplo).
- Librerías: `numpy`, `scipy.stats`, `matplotlib`, `seaborn`.

Ejercicios

1. Simulación y PDF/PMF: con `rng = np.random.default_rng(42)`, generá 10 000 muestras de cada una de las 4 distribuciones con parámetros razonables. Para cada una: histograma con `density=True` superpuesto con la PDF/PMF teórica de `scipy.stats`.
2. Cuantiles: calculá `scipy.stats.norm(loc=100, scale=15).ppf([0.025, 0.5, 0.975])` (IQ test → IC 95 % poblacional) y verificá que el 2.5 % y 97.5 % muestrales de una simulación con `n=100_000` se acerquen.
3. TCL en acción: tomá $\text{Exp}(\lambda=1)$ (claramente no normal). Generá 5 000 promedios de tamaños $n \in \{1, 5, 30, 100\}$ y graficá los 4 histogramas lado a lado. Verificá cómo se va volviendo simétrico y campaniforme.
4. Q-Q plot: `scipy.stats.probplot(tips.total_bill, dist='norm', plot=plt)`. Anotá qué muestra el extremo derecho (asimetría positiva → cola larga arriba de la diagonal).
5. ¿Poisson o no?: con los conteos por hora del dataset sintético, calculá `mean()` y `var()`. Si `var/mean` $[0.8, 1.2]$, equidispersión → Poisson plausible. Probá con `lam=4.2` (deberías ver `ratio ≈ 1`) y con datos contaminados (mezclá con `rng.poisson(20, size=200)` para ver overdispersión).

Homework verifiable

Notebook que:

1. Carga `tips.total_bill` de `seaborn`.
2. Genera un Q-Q plot contra 'norm' y otro contra 'lognorm'.
3. Aplica `scipy.stats.kstest` contra ambas (estandarizando los datos).
4. Concluye por escrito qué distribución modela mejor `total_bill` y por qué (≤ 3 líneas).

Criterio de aceptación: el p-value del KS contra lognormal debe ser mayor que contra normal, y la conclusión

debe mencionar que `total_bill` está acotado por abajo en 0 y tiene cola derecha — incompatible con normal.

Errores comunes

Síntoma / mensaje	Causa y cómo arreglar
<code>kstest</code> da <code>p=0.0</code> aunque los datos "se ven n	Probablemente no estandarizaste. KS contra
Histograma no coincide con la PDF teórica	Olvidaste <code>density=True</code> en <code>plt.hist</code> . Sin es
Aplico Poisson y la varianza es mucho mayo	Sobre-dispersión: hay heterogeneidad ocult
<code>np.random.seed(42)</code> no me da resultados rep	El estado global está deprecado para análi
Asumo normalidad con <code>n=8</code> porque "el TCL lo	El TCL es asintótico. Con <code>n</code> chico y distri

Preguntas frecuentes

¿Cuándo uso `scipy.stats.norm(loc, scale)` vs `np.random.normal(mu, sigma)`?

Para simular muestras: ambos funcionan, pero `rng = np.random.default_rng(seed)`; `rng.normal(...)` es el patrón moderno reproducible. Para calcular PDF, CDF, cuantiles: `scipy.stats.norm`, que es un objeto distribución con todos los métodos.

¿Poisson y binomial con `n` grande y `p` chica se parecen?

Sí: si $n \rightarrow \infty$ y $p \rightarrow 0$ con $np = \lambda$ constante, $\text{Bin}(n, p) \rightarrow \text{Poi}(\lambda)$. Por eso "1 cada 1000" se modela igual con cualquiera de las dos. En la práctica, si $n \geq 100$ y $p \leq 0.05$, son intercambiables.

¿La distribución t-Student es lo mismo que la normal?

No, pero converge. $t(v)$ con $v \rightarrow \infty$ tiende a $N(0,1)$. Para $v \geq 30$ son visualmente idénticas. La diferencia importa en muestras chicas (la t tiene colas más pesadas, lo que produce intervalos de confianza más anchos — correcto cuando estimás σ).

¿Mis datos tienen que ser normales para hacer un t-test?

No exactamente. Lo que tiene que ser $\approx$ normal es la distribución muestral de la media, y por TCL eso pasa con $n \geq 30$ aunque los datos crudos no lo sean. Si $n < 30$ y los datos están sesgados, usá bootstrap (Clase 153) o Mann-Whitney (Clase 150).

¿Por qué exponencial es "sin memoria"?

Porque $P(X > s + t \mid X > s) = P(X > t)$. Aplicado a un servidor que lleva 3 h sin caer: la probabilidad de aguantar otra hora es la misma que la de aguantar una hora desde 0. Para sistemas con desgaste (motores, humanos), usá Weibull o Gamma.

Referencias

- ISLP (James et al.), cap. 2 — Statistical Learning, sección sobre distribuciones.
- Bruce, P. & Bruce, A. Practical Statistics for Data Scientists (2ª ed., O'Reilly), cap. 2 Data and Sampling Distributions.
- `scipy.stats` reference — objetos norm, binom, poisson, expon.
- `numpy.random.Generator` — API moderna recomendada desde NumPy 1.17.
- 3Blue1Brown — Why π appears in the normal distribution (intuición visual del TCL).

Material descargable

- Guía explicativa (PDF) — versión imprimible con todo el contenido de la clase.
- Presentación (PPTX) — deck PowerPoint listo para proyectar en clase.
- Notebook ejecutable (.ipynb) — abrilo desde el laboratorio del programa o desde Jupyter.

Siguiente clase

Clase 176 — Test t (una muestra, dos muestras, pareado)

Apéndice: notebook (primer bloque)

Simétrica, soporte en toda la recta. Base de t-test, ANOVA e intervalos de confianza. Verificamos la regla 68-95-99.7.

```
import numpy as np
from scipy import stats
import matplotlib.pyplot as plt

rng = np.random.default_rng(42)
np.random.seed(42)

mu, sigma = 100.0, 15.0
x = rng.normal(mu, sigma, 10_000)
print(f"Normal N(100, 15^2): media={x.mean():.2f} sd={x.std(ddof=1):.2f}")

for k in (1, 2, 3):
    frac = np.mean(np.abs(x - mu) < k * sigma)
    print(f" dentro de {k} sigma: {frac:.3f}")
frac1 = np.mean(np.abs(x - mu) < sigma)
assert abs(frac1 - 0.683) < 0.02, "la regla 68-95-99.7 debe cumplirse"

grid = np.linspace(mu - 4sigma, mu + 4sigma, 200)
plt.figure(figsize=(7, 4))
plt.hist(x, bins=50, density=True, alpha=0.5, label="muestra")
plt.plot(grid, stats.norm(mu, sigma).pdf(grid), "r-", lw=2, label="PDF teórica")
plt.title("Distribución normal: histograma vs PDF"); plt.legend()
plt.tight_layout(); plt.show()
```

Archivos complementarios

- notebook.ipynb