

---

## **Clase 176 — Test $t$ (una muestra, dos muestras, pareado)**

Parte: 3 — Estadística Inferencial y Causal · Fuente: ISLP, cap. 13 + Bruce & Bruce, cap. 3  
Statistical Experiments and Significance Testing. Duración estimada: 80 min.

## Clase 176 — Test t (una muestra, dos muestras, pareado)

*Parte: 3 — Estadística Inferencial y Causal · Fuente: ISLP, cap. 13 + Bruce & Bruce, cap. 3 Statistical Experiments and Significance Testing. Duración estimada: 80 min.*

### Objetivo

Que el alumno aplique correctamente las tres variantes del test t —una muestra, dos muestras independientes (Welch por default), pareado—, distinga hipótesis nula y alternativa, lea p-value e intervalo de confianza de la salida de `scipy.stats` y `pingouin`, y aprenda a reportar effect size (Cohen's d, Hedges' g) junto con el p-value para no caer en la trampa de "significativo pero irrelevante".

### Resultados de aprendizaje

Al finalizar, el estudiante podrá:

- Formular  $H_0$  y  $H_a$  (bilateral / unilateral) para un problema concreto y elegir la variante correcta del test t.
- Ejecutar `scipy.stats.ttest_1samp`, `ttest_ind(equal_var=False)` y `ttest_rel`, interpretando el statistic, pvalue y el atributo `.confidence_interval()` (`scipy` ≥ 1.10).
- Verificar supuestos: normalidad por grupo (Shapiro / Q-Q plot) o invocar TCL si  $n \geq 30$ .
- Decidir entre test bilateral vs unilateral sin caer en p-hacking (la dirección debe estar fijada antes de mirar los datos).
- Reportar effect size: Cohen's d, Hedges' g corregido para muestras chicas, y su interpretación cualitativa (small/medium/large).

### Temas

- $H_0$  /  $H_a$ , errores tipo I ( $\alpha$ ) y tipo II ( $\beta$ ).
- Test t de una muestra:  $t = (\bar{x} - \mu) / (s/\sqrt{n})$ ,  $gl = n - 1$ .
- Test t de dos muestras independientes: Welch (varianzas distintas, default moderno) vs Student (varianzas iguales — supuesto fuerte, casi nunca correcto).
- Test t pareado (mismo sujeto antes/después).
- p-value: probabilidad bajo  $H_0$  de observar algo al menos tan extremo. NO es  $P(H_a | \text{datos})$ .
- Intervalo de confianza al 95 % como complemento del p-value.
- Complemento moderno: effect size (Cohen's d, Hedges' g, Cliff's  $\delta$ ) — la pregunta "¿es relevante?" que el p-value no responde.

### Versión profundizada — 2026

El tema moderno que antes vivía como complemento dentro de esta clase ahora tiene su(s) clase(s) propia(s) con patrón completo, ejercicios y homework:

- Clase 147a — Effect size dedicado: Cohen's d, Hedges' g, Cliff's  $\delta$  con `pingouin`

### Definiciones y características

- Hipótesis nula  $H_0$ : la afirmación "conservadora" — no hay diferencia, o la diferencia es 0. Se busca rechazarla, no probarla.
- Hipótesis alternativa  $H_1$ : lo que querés demostrar. Bilateral ( $\neq$ ) o unilateral ( $>$ ,  $<$ ).
- p-value:  $P(\text{estadístico al menos tan extremo como el observado} \mid H \text{ verdadera})$ . Si  $p < \alpha$ , rechazo  $H_0$ . NO es la probabilidad de que  $H_0$  sea verdadera.
- $\alpha$  (alpha): probabilidad máxima de error tipo I (rechazar  $H_0$  siendo verdadera). Convencional: 0.05. Para problemas críticos: 0.01 o 0.001.
- $\beta$  (beta): probabilidad de error tipo II (no rechazar  $H_0$  siendo falsa). Poder =  $1 - \beta$  (Clase 154).
- Welch's t-test: variante que no asume varianzas iguales. Es el default razonable. `equal_var=True` (Student clásico) es legacy.
- Test pareado: cuando cada observación de un grupo tiene su "par" en el otro (mismo paciente antes/después, misma página web con/sin cambio). Reduce varianza al diferenciar dentro del par.
- Cohen's d: magnitud estandarizada de la diferencia.  $d = 0.2/0.5/0.8 \rightarrow \text{small/medium/large}$ .
- `alternative='greater'`: unilateral derecho. Solo legítimo si la dirección la fijaste antes de ver los datos.

## Dataset / recursos

- `seaborn.load_dataset('tips')`: comparar tip entre `sex='Male'` vs `'Female'`, o `time='Lunch'` vs `'Dinner'`.
- Para pareado: simular un dataset antes/después con `numpy.random.default_rng` (presión arterial pre/post fármaco).
- Librerías: `scipy.stats`, `pingouin` (pip install pingouin), `seaborn`.

## Ejercicios

1. Una muestra: con `tips.total_bill`, testá  $H_0: \mu = 20$  vs  $H_1: \mu \neq 20$  con `scipy.stats.ttest_1samp(tips.total_bill, popmean=20)`. Reportá t, p y el IC95 % (`.confidence_interval()`).
2. Dos muestras (Welch): testá si tip difiere entre `sex='Male'` y `sex='Female'` con `ttest_ind(equal_var=False)`. Calculá Cohen's d a mano y verificá contra `pingouin.ttest`.
3. Pareado: simulá presión arterial antes/después de un fármaco con `rng = np.random.default_rng(0)`: `antes = rng.normal(140, 12, 30)`, `despues = antes - rng.normal(5, 3, 30)`. Aplicá `ttest_rel(antes, despues)` y comparalo contra hacer `ttest_ind` mal (verás cómo el pareado tiene mucho más poder).
4. Bilateral vs unilateral: para el ejercicio 2, repetí con `alternative='greater'` y `'less'`. Observá cómo el p-value se divide  $\approx 2$ .
5. Significativo vs relevante: generá `grupo_a = rng.normal(100, 15, 10_000)` y `grupo_b = rng.normal(100.5, 15, 10_000)`. El test va a dar  $p < 0.001$ ; calculá Cohen's d y discutí en 2 líneas por qué el resultado "no importa".

## Homework verifiable

Sobre tips:

1. Hipótesis: la propina promedio es distinta para `time='Lunch'` y `time='Dinner'`.
2. Verificar normalidad de cada grupo con `pingouin.normality` (Shapiro).
3. Ejecutar `pingouin.ttest` y reportar: T, gl, p-value, IC95 %, Cohen's d, power.
4. Una conclusión de 3 líneas que mencione (a) si rechazás  $H_0$ , (b) la magnitud del efecto en palabras (small/medium/large), (c) si recomendarías ese hallazgo a un dueño de restaurante.

Criterio de aceptación: el reporte debe incluir effect size y la conclusión no puede limitarse a " $p < 0.05$ ". Si Cohen's d es  $< 0.2$ , la respuesta a (c) debería ser "no" aunque el p sea bajo.

## Errores comunes

| Síntoma / mensaje                                                    | Causa y cómo arreglar                                   |
|----------------------------------------------------------------------|---------------------------------------------------------|
| Aplico <code>ttest_ind</code> con <code>equal_var=True</code> por co | Student clásico con varianzas desiguales y              |
| $p < 0.05$ con $n = 10^6$ y declaro un hallazgo                      | "Significancia estadística" con muestra $gi$            |
| Cambio <code>alternative='greater'</code> después de ve              | Eso es p-hacking. La dirección se fija con              |
| Aplico <code>ttest_ind</code> a observaciones pareadas               | Pierde poder enormemente y puede dar $p > 0$            |
| El test asume normalidad y mis datos son m                           | Welch es robusto pero no mágico. Fix: <code>scip</code> |

## Preguntas frecuentes

¿Welch o Student por default?

Welch siempre. No cuesta nada en poder cuando las varianzas son iguales, y protege contra el caso (muy común) de varianzas distintas. La literatura moderna (Delacre, Lakens & Leys 2017) recomienda abandonar el Student t-test.

¿Tengo que testear normalidad antes del t-test?

No con  $n \geq 30$  por grupo (TCL). Con  $n$  chico y datos visiblemente asimétricos, sí — y si Shapiro rechaza, mejor pasar a bootstrap o Mann-Whitney. Cuidado: con  $n$  enorme, Shapiro rechaza siempre por desviaciones triviales; mirá Q-Q plot como complemento.

¿Qué es BF10 que reporta pinguin?

Factor de Bayes contra  $H_0$ .  $BF_{10} > 3$  es evidencia moderada a favor de  $H_1$ ;  $> 10$  fuerte. Es la versión bayesiana del p-value y no tiene los problemas del NHST (la testeás directamente en la Clase 158).

¿Por qué el IC95 % de la diferencia y el p-value siempre concuerdan?

Porque son la misma información presentada de otra forma. Si el IC95 % de  $\mu_a - \mu_b$  no incluye 0, entonces  $p < 0.05$  (bilateral). Reportar el IC es más informativo: muestra magnitud y dirección.

Cohen's d me da 0.3, ¿cómo lo explico al cliente?

"Un efecto pequeño-mediano". Operacionalmente: si dibujás las dos distribuciones, el  $\approx 55$  % de los individuos del grupo tratamiento superan a la mediana del grupo control (vs 50 % bajo  $H_0$ ). Para una conversión, tradúcelo a "incremento absoluto de X puntos porcentuales".

## Referencias

- ISLP, cap. 13 — Multiple Testing, intro al p-value.
- Bruce & Bruce, cap. 3 — Statistical Experiments and Significance Testing.
- Delacre, Lakens & Leys (2017), Why Psychologists Should by Default Use Welch's t-test, IRSP.
- Cohen, J. (1988), Statistical Power Analysis for the Behavioral Sciences — referencia canónica de effect size.
- pingouin docs — Vallat, R. (2018), Pingouin: statistics in Python, JOSS.
- `scipy.stats.ttest_ind` — atención a `equal_var` y `alternative`.

## Material descargable

- Guía explicativa (PDF) — versión imprimible con todo el contenido de la clase.
- Presentación (PPTX) — deck PowerPoint listo para proyectar en clase.
- Notebook ejecutable (.ipynb) — abrilo desde el laboratorio del programa o desde Jupyter.

## Siguiente clase

Clase 177 — Effect size dedicado: Cohen's d, Hedges' g, Cliff's  $\delta$  con pingouin

## Apéndice: notebook (primer bloque)

H:  $\mu = 20$  vs H:  $\mu \neq 20$ . El IC95 % y el p-value son la misma información: si el IC excluye 20, se rechaza H.

```
import numpy as np
from scipy import stats
import matplotlib.pyplot as plt

rng = np.random.default_rng(42)

total_bill = rng.normal(21.5, 8, 200)
res = stats.ttest_1samp(total_bill, popmean=20)
ci = res.confidence_interval(0.95)
print("H0:  $\mu=20$  vs H1:  $\mu \neq 20$ ")
print(f"t={res.statistic:.3f} p={res.pvalue:.4f} IC95%=(ci.low:.2f, ci.high:.2f)")
print("Rechazo H0" if res.pvalue < 0.05 else "No rechazo H0")
excluye_20 = ci.low > 20 or ci.high < 20
assert (res.pvalue < 0.05) == excluye_20, "p-value e IC deben concordar"
```

## Archivos complementarios

- notebook.ipynb