
Clase 062 — Clasificación binaria con MNIST

Parte: 1 — Machine Learning Clásico · Fuente: Géron, cap. 3. Duración estimada: 60 min. ·

Nivel: Intermedio

Clase 062 — Clasificación binaria con MNIST

Parte: 1 — Machine Learning Clásico · Fuente: Géron, cap. 3. Duración estimada: 60 min. · Nivel: Intermedio

Objetivo

Que el alumno arme su primer clasificador binario "de verdad" sobre MNIST (¿este dígito es un 5 o no?), entrenando un `SGDClassifier`, evaluándolo con `cross_val_score` sobre `StratifiedKFold`, y entendiendo por qué la accuracy sola miente cuando las clases están desbalanceadas.

Resultados de aprendizaje

Al finalizar la clase, el alumno podrá:

1. Cargar MNIST con `fetch_openml('mnist_784', as_frame=False)` y separar train/test respetando el split original (60k/10k).
2. Construir un target binario `y_train_5 = (y_train == 5)` y entrenar un `SGDClassifier` sobre él.
3. Predecir y obtener scores con `predict()` y `decision_function()`, entendiendo la diferencia entre clase y score continuo.
4. Validar con `cross_val_score` sobre `StratifiedKFold` y leer los 3 valores que devuelve.
5. Detectar el accuracy paradox: comparar contra un clasificador trivial "nunca-5" y ver que también saca ~90%.

Temas

#	Tema	Por qué importa
1	<code>fetch_openml('mnist_784')</code>	Dataset estándar de entrada a CV/ML; 70k i
2	Target binario 5 vs no-5	Forma canónica de empezar antes de meterse
3	<code>SGDClassifier(random_state=42)</code>	Lineal, escalable, online; el "hola mundo"
4	<code>cross_val_score</code> + <code>StratifiedKFold</code>	Mantiene la proporción de clases en cada f
5	Accuracy paradox	90% suena bien hasta que ves que Never5Cla
6	<code>predict</code> vs <code>decision_function</code> vs <code>predict_pr</code>	Score continuo es lo que después te deja m

Definiciones y características

MNIST

: Dataset de 70.000 imágenes de dígitos manuscritos (0-9), 28×28 píxeles en escala de grises, aplanadas a vectores de 784 features. Split convencional: 60k train + 10k test, ya barajado. Es el "hello world" de ML — chico, limpio, sin sorpresas.

SGDClassifier

: Clasificador lineal entrenado con Stochastic Gradient Descent. Procesa instancias de a una (o mini-batch), lo que lo hace ideal para datasets grandes y aprendizaje online. Sensible al `random_state` (fijarlo siempre para reproducibilidad).

`decision_function(X)`

: Devuelve el score crudo (distancia firmada al hiperplano de decisión), no la clase. $\text{Score} > 0 \rightarrow$ clase positiva, $\text{score} < 0 \rightarrow$ negativa. Es lo que vas a necesitar después para mover el umbral y construir curvas PR/ROC.

Accuracy

: $(\text{TP} + \text{TN}) / \text{total}$. Métrica obvia pero traicionera: si el 90% de tus instancias son de la clase negativa, predecir "siempre negativo" te da 90% sin haber aprendido nada.

Baseline trivial (dummy classifier)

: Modelo que predice siempre la clase mayoritaria (o aleatorio). Sirve de piso: si tu modelo no le gana al dummy, no aprendió. En 5-vs-no-5, el dummy "nunca-5" saca ~90.9% (porque solo ~9.1% de los dígitos son 5).

StratifiedKFold

: Variante de K-Fold que conserva la proporción de clases en cada fold. Imprescindible con desbalanceo: con K-Fold común podrías terminar con un fold sin un solo 5.

`cross_val_score(clf, X, y, cv=3, scoring='accuracy')`

: Entrena y evalúa `clf` en `cv` folds y devuelve un array de `cv` scores. Por default usa `StratifiedKFold` cuando la tarea es clasificación.

Dataset / recursos

Nota — dataset en el notebook: el notebook de esta clase usa `load_digits` de `scikit-learn` (dígitos manuscritos de $8 \times 8 = 64$ features, ~1.800 imágenes, incluido en la librería) como sustituto offline de MNIST. La técnica y el flujo (clasificador binario 5-vs-no-5, `cross_val_score`, accuracy que engaña con clases desbalanceadas) son idénticos; se eligió `load_digits` para que la clase corra sin descargar los ~55 MB de MNIST ni depender del servidor de OpenML. El texto que sigue describe MNIST completo (`fetch_openml`) para quien quiera replicarlo a escala real.

MNIST vía `fetch_openml` (se cachea localmente en `~/scikit_learn_data/` después de la primera descarga):

```
from sklearn.datasets import fetch_openml
mnist = fetch_openml('mnist_784', as_frame=False, parser='auto')
X, y = mnist.data, mnist.target.astype(int)
X_train, X_test = X[:60000], X[60000:]
y_train, y_test = y[:60000], y[60000:]
y_train_5 = (y_train == 5)
y_test_5 = (y_test == 5)
```

Ejercicios

1. Cargar y explorar. Cargá MNIST, imprimí `X.shape` y `y.shape`, mostrá un dígito con `matplotlib.imshow(X[0].reshape(28, 28), cmap='binary')` y verificá que `y[0] == 5`.
2. Target binario + SGD. Construí `y_train_5`, entrená `SGDClassifier(random_state=42)` y predecí sobre `X[0]`. ¿Devuelve True?
3. `decision_function`. Sobre la misma instancia, llamá a `decision_function([X[0]])` y compará el signo con el resultado de `predict`.

4. Cross-validation. Corré `cross_val_score(sgd, X_train, y_train_5, cv=3, scoring='accuracy')`. ¿Qué tres valores te da? ¿Cuál es el promedio?

5. Baseline trampa. Implementá un `Never5Classifier` (clase con `fit` que no hace nada y `predict` que devuelve `np.zeros(len(X), dtype=bool)`) y corré el mismo `cross_val_score`. Comparalo con el SGD: ¿la diferencia es la que esperabas?

Homework verifiable

Notebook que: (a) carga MNIST y arma el target 5-vs-no-5; (b) entrena `SGDClassifier(random_state=42)` sobre el train completo; (c) reporta accuracy 3-fold con `cross_val_score`; (d) reporta accuracy 3-fold del `Never5Classifier`; (e) en una celda markdown, explica en 2-3 líneas por qué ambos modelos están "cerca" en accuracy y por qué eso no significa que sean equivalentes.

Criterio de aceptación: Accuracy del SGD ≥ 0.95 en los 3 folds, accuracy del dummy ≈ 0.909 en los 3 folds, y la celda markdown menciona explícitamente el desbalanceo (~9% de 5s) como causa del paradox.

Errores comunes

Síntoma / mensaje	Causa y cómo arreglar
"¡Mi modelo saca 90% de accuracy, está gen	Trampa clásica con clases desbalanceadas.
<code>fetch_openml</code> tarda eternidades o falla	La primera vez descarga ~55MB y a veces el
y viene como strings ('5', '0', ...) y la	Por default OpenML devuelve labels como st
Resultados distintos cada vez que entrenás	<code>SGDClassifier</code> es estocástico. Fix: <code>SGDClas</code>
<code>decision_function</code> no existe / <code>AttributeErr</code>	Algunos clasificadores (como <code>RandomForest</code>)

Preguntas frecuentes

¿Por qué arrancar con clasificación binaria si MNIST es multiclase?

Pedagógico: binario aísla los conceptos de score, umbral, precision/recall sin el ruido de "¿es 3 o 8?". Multiclase viene en la clase 059 (One-vs-Rest, One-vs-One).

¿`SGDClassifier` con `loss='hinge'` (default) es lo mismo que SVM?

Es un SVM lineal entrenado con SGD en vez de con el optimizador cuadrático de SVC. Misma frontera teórica, distinta forma de llegar. Para datasets grandes, SGD le gana en tiempo.

¿Por qué `cv=3` y no `cv=10`?

Géron usa 3 porque MNIST es grande (60k×784) y 10 folds tarda. En datasets chicos, 5-10 es lo habitual. La regla: más folds = menos varianza en la estimación pero más cómputo.

¿`predict_proba` está disponible en `SGDClassifier`?

Solo si entrenás con `loss='log_loss'` (regresión logística) o `loss='modified_huber'`. Con el default 'hinge' no — usás `decision_function`.

¿Hace falta escalar las features de MNIST?

Para `SGDClassifier` sí, conviene (los píxeles 0-255 son grandes y SGD es sensible a escala). Géron en el cap. 3 lo omite para simplificar; en la práctica `StandardScaler` o dividir por 255 ayuda a la convergencia.

Referencias

- Géron, cap. 3 § "Training a Binary Classifier" y "Measuring Accuracy Using Cross-Validation".
- sklearn SGDClassifier
- sklearn fetch_openml
- sklearn StratifiedKFold

Material descargable

- Guía explicativa (PDF) — versión imprimible con todo el contenido de la clase.
- Presentación (PPTX) — deck PowerPoint listo para proyectar en clase.
- Notebook ejecutable (.ipynb) — abrilo desde el laboratorio del programa o desde Jupyter.

Siguiente clase

Clase 063 — Métricas: confusion matrix, precision, recall, F1

Apéndice: notebook (primer bloque)

Primer clasificador binario "de verdad": ¿este dígito es un 5 o no? Entrenamos un SGDClassifier, validamos con StratifiedKFold y descubrimos por qué la accuracy sola miente cuando las clases están desbalanceadas.

> Nota: usamos load_digits() (imágenes 8×8, sin conexión a internet) en lugar de MNIST 28×28, pero el planteo es idéntico. Requiere: numpy, scikit-learn, matplotlib.

```
import numpy as np
import matplotlib.pyplot as plt
from sklearn.datasets import load_digits
from sklearn.linear_model import SGDClassifier
from sklearn.model_selection import StratifiedKFold, cross_val_score, train_test_split
from sklearn.base import BaseEstimator

np.random.seed(42)

digits = load_digits()
X, y = digits.data, digits.target
print('X', X.shape, 'y', y.shape)
print('clases:', np.unique(y))
print('proporcion de 5s: {:.3f}'.format((y == 5).mean()))
```

Archivos complementarios

- notebook.ipynb