
Clase 125 — TFRecord

Parte: 2 — Deep Learning · Fuente: Géron, cap. 13 § The TFRecord Format. Duración estimada: 60 min. · Nivel: Avanzado

Clase 125 — TFRecord

Parte: 2 — Deep Learning · Fuente: Géron, cap. 13 § The TFRecord Format. Duración estimada: 60 min. · Nivel: Avanzado

Objetivo

Aprender el formato TFRecord — el formato binario nativo de TF, optimizado para datasets grandes (cientos de GB) que no caben en RAM. Saber escribirlo (`tf.io.TFRecordWriter`), parsearlo (`tf.io.parse_single_example`), y por qué es estándar en TPU/Vertex AI para training a escala.

Resultados de aprendizaje

Al finalizar, el estudiante podrá:

- Serializar un `tf.train.Example` con Features ↔ Feature (`ByteList`, `Int64List`, `FloatList`).
- Escribir TFRecord shards: with `tf.io.TFRecordWriter('file.tfrecord')` as `w`: `w.write(serialized)`.
- Leer con `tf.data.TFRecordDataset('file.tfrecord').map(parse_fn)`.
- Splitear datasets grandes en múltiples shards (`*.tfrecord-00000-of-00010`) para paralelizar reads.
- Reconocer cuándo TFRecord vale la pena vs alternativas modernas (Parquet, WebDataset).

Temas

- `tf.train.Example`: estructura protobuf con Features (dict de strings a Feature).
- Feature types: `ByteList`, `Int64List`, `FloatList`.
- Serialize → escribir → leer → parse.
- Sharding: `data.tfrecord-NNNNN-of-MMMMM`.
- `tf.data.experimental.bucket_by_sequence_length` para batches eficientes por longitud (NLP).

Definiciones y características

- TFRecord: archivo binario de records seriales protobuf. Eficiente, splitteable, compresible.
- `tf.train.Example`: proto que envuelve un dict de features.
- `SerializeToString()`: convierte el Example en bytes para escribir.
- `parse_single_example(serialized, feature_spec)`: parsea con un schema declarado.
- Sharding: dividir un dataset en N archivos → reads paralelos vía interleaved.

Dataset / recursos

- Fashion-MNIST exportado a TFRecord.
- Librerías: tensorflow.

Ejercicios

1. Escribir: convertir Fashion-MNIST (60 000 imágenes) a 10 shards TFRecord. Cada Example tiene image (bytes) y label (int).

2. Leer y parsear: `ds = tf.data.TFRecordDataset(glob.glob('shards/*.tfrecord')).map(parse_fn)`. Iterar y verificar shapes.
3. Compresión: escribir con `options=tf.io.TFRecordOptions(compression_type='GZIP')`. Comparar tamaño.
4. Reads paralelos: `ds = ds.interleave(lambda f: tf.data.TFRecordDataset(f), num_parallel_calls=AUTOTUNE)`. Medir speedup vs lectura serial.
5. Schema: usar `tf.io.FixedLenFeature` (tamaño fijo) vs `VarLenFeature` (variable, returns `SparseTensor`).

Homework verifiable

Pipeline completo de Fashion-MNIST con TFRecord:

1. Escribir 10 shards.
2. Leer con `interleave + map + batch + prefetch`.
3. Entrenar un modelo y comparar tiempo vs cargar desde NumPy.

Criterio de aceptación: el pipeline TFRecord debe escalar mejor cuando los datos no caben en RAM (simular limitando RAM si es necesario); para Fashion-MNIST en RAM, los tiempos deben ser similares.

Errores comunes

Síntoma / mensaje	Causa y cómo arreglar
<code>parse_single_example</code> falla con "Key not fo	Schema no coincide con lo escrito. Fix: im
Tamaño TFRecord enorme	No comprimiste. Fix: <code>compression_type='GZI</code>
<code>tf.io.parse_tensor</code> vs <code>parse_single_example</code>	Para tensores serializados con <code>tf.io.seria</code>
Reads serializados secuenciales en un únic	El throughput está limitado por 1 disco. F
Sin <code>drop_remainder</code> los últimos batches tie	Algunos modelos rompen. Fix: <code>batch(N, drop</code>

Preguntas frecuentes

¿TFRecord o Parquet?

TFRecord para TF/JAX. Parquet para data science general (Polars, Spark, DuckDB). PyTorch tiene `WebDataset` que es similar a TFRecord pero más portable (tarballs).

¿Cuándo TFRecord es necesario?

Cuando los datos no caben en RAM (>10 GB) y querés training rápido. Para datasets chicos (< 1 GB), arrays NumPy alcanzan.

¿Cuántos shards?

Regla práctica: 100-1000 archivos, cada uno 100 MB - 1 GB. Para TPU training, ≥ 8 shards por nodo.

¿Comprimir o no?

Comprimir si I/O es el bottleneck. Si CPU es el cuello (decode lento), no comprimir. Probá ambos.

¿Hugging Face datasets?

Sí, formato moderno (basado en Arrow/Parquet) con caching automático y API más amigable. Para LLMs, default industrial. Saber TFRecord es útil legacy pero datasets lo está reemplazando.

Referencias

- Géron, cap. 13 — The TFRecord Format.
- TF — TFRecord and tf.train.Example.
- WebDataset — alternativa PyTorch.
- Hugging Face datasets — alternativa moderna multi-framework.

Material descargable

- Guía explicativa (PDF) — versión imprimible con todo el contenido de la clase.
- Presentación (PPTX) — deck PowerPoint listo para proyectar en clase.
- Notebook ejecutable (.ipynb) — abrilo desde el laboratorio del programa o desde Jupyter.

Siguiente clase

Clase 126 — Keras preprocessing layers

Apéndice: notebook (primer bloque)

Primera celda ejecutable del notebook de la clase.

```
import glob
import numpy as np
import tensorflow as tf
from tensorflow import keras
keras.utils.set_random_seed(42)

def _bytes_feature(valor):
    if isinstance(valor, type(tf.constant(0))):
        valor = valor.numpy()
    return tf.train.Feature(bytes_list=tf.train.BytesList(value=[valor]))

def _int64_feature(valor):
    return tf.train.Feature(int64_list=tf.train.Int64List(value=[valor]))

def _float_feature(valor):
    return tf.train.Feature(float_list=tf.train.FloatList(value=[valor]))

print("helpers de Feature listos: bytes / int64 / float")
```

Archivos complementarios

- notebook.ipynb