
Clase 188 — Inferencia causal: DAGs, confounders, instrumentos

Parte: 3 — Estadística Inferencial y Causal · Fuente: Pearl, The Book of Why + Hernán & Robins, Causal Inference: What If (libro gratuito, 2024) + Imbens & Rubin. Duración estimada: 95 min. · Nivel: Avanzado

Clase 188 — Inferencia causal: DAGs, confounders, instrumentos

Parte: 3 — Estadística Inferencial y Causal · Fuente: Pearl, *The Book of Why* + Hernán & Robins, *Causal Inference: What If* (libro gratuito, 2024) + Imbens & Rubin. Duración estimada: 95 min. · Nivel: Avanzado

Objetivo

Distinguir correlación de causalidad con rigor: dibujar DAGs (Directed Acyclic Graphs), identificar confounders, colliders y mediators, aplicar el backdoor criterion para decidir qué variables controlar, y usar variables instrumentales (IV) cuando la randomización no es posible. Conocer la herramienta moderna Double Machine Learning (DoubleML / EconML) para estimar ATE/CATE con ML como nuisance estimator.

Resultados de aprendizaje

Al finalizar, el estudiante podrá:

- Dibujar un DAG para un problema de negocio e identificar los tres tipos de estructura: chain ($X \rightarrow M \rightarrow Y$), fork ($X \leftarrow Z \rightarrow Y$, confounder), collider ($X \rightarrow C \leftarrow Y$).
- Aplicar el backdoor criterion de Pearl: encontrar el conjunto mínimo de variables a controlar para identificar el efecto causal.
- Reconocer que controlar por un collider o un mediator introduce sesgo, NO lo elimina.
- Estimar ATE (Average Treatment Effect) con regresión + controles, IPW (Inverse Probability Weighting) y matching.
- Usar 2SLS (Two-Stage Least Squares) con `linearmodels.iv` cuando hay un instrumento válido.
- Aplicar Double Machine Learning con `doubleml` / `econml` para estimar ATE/CATE con ML como nuisance (sin asumir linealidad).

Temas

- Correlación $\neq$ causalidad: el clásico ejemplo "helado y ahogamientos" — confounder: temperatura.
- DAGs: nodos = variables, flechas = relación causal.
- 3 estructuras canónicas: chain, fork, collider.
- Backdoor criterion: bloquear todos los caminos no causales de X a Y; no abrir colliders.
- $ATE = E[Y | do(T=1)] - E[Y | do(T=0)]$. El "do" indica intervención, no observación.
- Identificación: ¿se puede expresar $E[Y | do(T)]$ con datos observacionales? Si sí $\rightarrow$ estimar.
- IV: variable Z que afecta T pero NO a Y excepto vía T. Permite identificar el efecto cuando hay confounders no observados.
- Complemento moderno: Double Machine Learning (Chernozhukov et al. 2018) — usa ML para estimar las "nuisance functions" y separa la inferencia causal de la complejidad del fit.

Versión profundizada — 2026

El tema moderno que antes vivía como complemento dentro de esta clase ahora tiene su(s) clase(s) propia(s) con patrón completo, ejercicios y homework:

- Clase 189 — DoubleML / EconML: Machine Learning para causalidad

Definiciones y características

- DAG: grafo dirigido acíclico que representa relaciones causales. Cada flecha es una hipótesis causal.
- Confounder (fork): $T \leftarrow Z \rightarrow Y$. Z causa tanto T como Y; controlando Z se identifica el efecto.
- Collider: $T \rightarrow C \leftarrow Y$. Controlar C introduce asociación espuria (sesgo de selección). Ejemplo clásico: Berkson's bias.
- Mediator (chain): $T \rightarrow M \rightarrow Y$. Controlar M bloquea el efecto causal indirecto y solo deja el directo (a veces útil, a veces no).
- Backdoor criterion (Pearl): un set Z de variables identifica el efecto causal de T sobre Y si: (a) bloquea todos los caminos backdoor (que empiezan con flecha entrando a T), y (b) no contiene descendientes de T.
- ATE (Average Treatment Effect): $E[Y(1) - Y(0)]$ — efecto promedio si todos vs nadie recibiera tratamiento.
- CATE (Conditional ATE): $E[Y(1) - Y(0) | X=x]$ — efecto para individuos con características $X=x$.
- Instrumento (IV): variable Z que satisface (a) relevancia (afecta a T), (b) exclusión (no afecta Y excepto vía T), (c) independencia (no comparte confounders con Y).
- 2SLS: estima IV ajustando $T = \alpha Z + \varepsilon$ (1ª etapa), reemplazando T en $Y = \theta T + \varepsilon$ (2ª etapa).
- DML: ML para nuisance + Neyman-orthogonal score + cross-fitting → inferencia causal robusta.

Dataset / recursos

- Ejemplos simulados de Pearl: smoking-cancer con tar como mediator.
- econml.tests.dgps para datos sintéticos con efectos heterogéneos conocidos.
- Lalonde 1986 (NSW job training program) — clásico de causal inference.
- Librerías: doubleml, econml, linearmodels, pgmpy (DAG inference), dowhy (Microsoft, framework completo).

Ejercicios

1. DAG en código: con pgmpy (o networkx), definí un DAG con T, Y, Z (confounder), C (collider). Identificá visualmente paths y aplicá dowhy para encontrar el adjustment set.
2. Sesgo del collider: simulá $T \sim N(0,1)$, $Y \sim N(T, 1)$, $C = T + Y + \varepsilon$. Estimá $Y \sim T$ sin controlar C y controlando C. Mostrá que controlar el collider destruye la relación causal.
3. Backdoor ajustando confounder: simulá Z , $T = f(Z) + \varepsilon$, $Y = 2T + 3Z + \delta$. OLS $Y \sim T$ sesgado. OLS $Y \sim T + Z$ recupera el 2.
4. 2SLS: simular un IV $Z \rightarrow T \rightarrow Y$ con confounder no observado entre T y Y. Aplicar `linearmodels.iv.IV2SLS.from_formula('Y ~ 1 + [T ~ Z]', data).fit()`. Recuperar el efecto verdadero.
5. DML con random forest: dataset sintético con confounders no lineales. Comparar OLS ingenuo vs OLS con polinomios vs DoubleMLPLR(`ml_g=RF`, `ml_m=RF`). Verificar que DML es el menos sesgado.

Homework verifiable

Sobre un dataset simulado de "efecto de un programa de capacitación sobre salario":

1. Generar X (edad, educación, experiencia) como confounders. Generar T (participa) con $P(T|X)$ no trivial. Generar Y con efecto causal $\theta_{\text{true}} = 2_000$.

2. Estimar el efecto con: (a) diferencia ingenua de medias, (b) OLS con controles lineales, (c) DoubleML con RF.
3. Comparar contra θ_{true} . Reportar bias y IC95 %.
4. Dibujar el DAG (puede ser un comentario con notación o un grafo simple).
5. Discutir en 3 líneas qué pasaría si hubieras controlado por un mediator (ej.: "horas trabajadas").

Criterio de aceptación: DML debe recuperar $\theta_{\text{true}} \pm 200$. OLS lineal puede estar sesgado si la relación $X \rightarrow Y$ no es lineal. La diferencia ingenua debe estar fuertemente sesgada. La discusión debe mencionar que controlar mediators sesga hacia 0.

Errores comunes

Síntoma / mensaje	Causa y cómo arreglar
Controlo "todo lo que tengo" en la regresi	Si entre esos hay colliders o mediators, i
Asumo que el coeficiente OLS es causal cua	No lo es. Fix: IV (si tenés instrumento),
Uso un instrumento débil (correlación con	2SLS con IV débil tiene sesgo y SE inflado
doubleml con n_folds=2 y muestra chica	Cross-fitting con pocos folds no estabiliz
Interpreto un coeficiente OLS como ATE sin	OLS = ATE solo bajo unconfoundedness. Fix:

Preguntas frecuentes

¿Cómo sé si dibujé bien el DAG?

No hay método estadístico para validarlo completamente — el DAG codifica supuestos sustantivos (de dominio). Lo que sí podés hacer: falsificación condicional — el DAG implica ciertas independencias condicionales; testealas con los datos y si fallan, el DAG está mal. `dowhy.refute_estimate` automatiza muchos refutation tests.

¿IV o DML cuando tengo ambos?

Si tenés un IV válido y confiable, IV es identificación más fuerte (resiste confounders no observados). DML solo aguanta confounders observados. Lo ideal: triangular con ambos.

¿Causal forest vs random forest clásico?

Causal forest no minimiza error de predicción; minimiza heterogeneidad del efecto causal entre hojas. Cada hoja contiene unidades con efecto causal similar.

¿Qué tan robusto es DML a especificación errónea?

DML es doubly robust: si o el modelo de g o el de m está bien especificado, el estimador del efecto es consistente. Cero modelos correctos $\rightarrow$ sesgo. Es la mejor garantía actual sin randomización.

¿Inferencia causal con datos observacionales puede reemplazar un RCT?

No completamente. RCT randomiza el tratamiento $\rightarrow$ corta todas las flechas backdoor por diseño. Observacional siempre depende de supuestos no testables (unconfoundedness, IV exclusion). El estándar es: RCT cuando se puede; cuasi-experimental (DiD, IV, RDD) cuando no; y reportar sensitivity analyses.

Referencias

- Pearl, J. (2018), The Book of Why — intuición sin matemática pesada.
- Pearl, J., Glymour, M. & Jewell, N. (2016), Causal Inference in Statistics: A Primer — el libro técnico corto.
- Hernán, M. & Robins, J. (2024), Causal Inference: What If. Libro gratuito.
- Chernozhukov et al. (2018), Double/Debiased Machine Learning for Treatment and Structural Parameters, Econometrics Journal.
- doubleml docs (Python + R).
- EconML docs — Microsoft Research.
- DoWhy — framework de identificación + estimación + refutación.

Material descargable

- Guía explicativa (PDF) — versión imprimible con todo el contenido de la clase.
- Presentación (PPTX) — deck PowerPoint listo para proyectar en clase.
- Notebook ejecutable (.ipynb) — abrilo desde el laboratorio del programa o desde Jupyter.

Siguiente clase

Clase 189 — DoubleML / EconML: Machine Learning para causalidad

Apéndice: notebook (primer bloque)

$T \leftarrow Z \rightarrow Y$. Z causa tanto T como Y . El OLS ingenuo $Y \sim T$ está sesgado; ajustar por Z recupera el efecto causal (backdoor criterion).

```
import numpy as np
import pandas as pd
import statsmodels.api as sm
import statsmodels.formula.api as smf
from statsmodels.sandbox.regression.gmm import IV2SLS
import matplotlib.pyplot as plt

rng = np.random.default_rng(42)

n = 5000
Z = rng.normal(0, 1, n)          # confounder
T = 0.8 * Z + rng.normal(0, 1, n) # tratamiento depende de Z
Y = 2.0 * T + 3.0 * Z + rng.normal(0, 1, n) # efecto causal verdadero de T = 2.0
df = pd.DataFrame({"Y": Y, "T": T, "Z": Z})
naive = smf.ols("Y ~ T", data=df).fit().params["T"]
adj = smf.ols("Y ~ T + Z", data=df).fit().params["T"]
print("efecto verdadero = 2.00")
print(f"OLS ingenuo Y~T = {naive:.3f} (sesgado por Z)")
print(f"OLS ajustado Y~T+Z = {adj:.3f} (recupera el efecto)")
assert abs(adj - 2.0) < 0.15 and abs(naive - 2.0) > 0.3
```

Archivos complementarios

- notebook.ipynb